

Proyecto Integrador Módulo 3

TechCore, Análisis de Ventas

Avance 1, Limpieza y Transformación de Datos

Simón Bedoya

Soy Henry, Carrera de Data Science

2026

Descripción del Avance

DataVision Analytics asignó la primera fase del proyecto para TechCore, una cadena de tiendas minoristas especializada en la venta de computadores y accesorios tecnológicos. El objetivo de esta etapa es importar, limpiar y preparar la base de datos cruda de facturación en Power BI, dejándola lista para los análisis y modelados de las etapas siguientes. Mi rol es el de Analista de Datos Junior, y el trabajo consiste en tomar el archivo de facturas tal como viene, con todos sus errores e inconsistencias, y transformarlo en un conjunto de datos confiable.

Toda la limpieza se hizo en Power Query, que es el editor de datos de Power BI Desktop. Power Query permite aplicar transformaciones y las registra como una secuencia de pasos, lo que deja documentado de forma automática todo el proceso. El resultado es un archivo de Power BI con los pasos aplicados y un archivo de datos limpio exportado para su uso posterior.

Objetivo del Avance

El objetivo es dejar la base de facturas limpia y estandarizada. Esto abarca cinco tareas: importar la base cruda, estandarizar los nombres de las columnas y los tipos de dato, detectar y manejar los valores nulos, duplicados e inconsistentes, normalizar los campos de texto como las categorías, las ciudades y los métodos de pago, y exportar el dataset limpio para el Avance 2. La meta de fondo es que los datos queden confiables, sin ambigüedades que dificulten el análisis.

La Herramienta, Power Query

Power Query es el componente de Power BI donde se importan y transforman los datos antes de analizarlos. Funciona de forma visual, aplicando transformaciones desde menús, y cada acción queda registrada en un panel llamado Pasos aplicados. Esa lista de pasos es valiosa por dos

razones. Primero, porque documenta el proceso completo, en orden, sin tener que escribirlo aparte. Segundo, porque las transformaciones no son destructivas: si un paso queda mal, se puede editar o eliminar sin perder los demás. Este avance completo vive dentro de Power Query, y el archivo de Power BI conserva toda la secuencia de limpieza.

Diagnóstico de los Datos Crudos

Antes de limpiar, se analizó el archivo para entender qué contiene y qué problemas tiene. La base cruda tiene treinta mil trescientas siete facturas y treinta columnas. Cada factura puede incluir hasta tres productos, por lo que hay grupos de columnas que se repiten para el producto uno, el dos y el tres, con su nombre, marca, cantidad, precio y subtotal. El análisis identificó ocho tipos de problemas, que se resumen a continuación.

Problema	Qué se encontró	Tratamiento
Facturas duplicadas	307 facturas totalmente repetidas	Se eliminan por VentaID
Nombres sin uniformar	Cliente_Nombre, Direccion_Cliente, edadcliente	Se estandarizan a formato pegado
Ciudades mal escritas	medellin, Medellin, medellín, Medellín	Se unifican a una forma correcta
Métodos de pago vacíos	1.459 facturas sin método	Se completan con No especificado
Marcas mal escritas	Lenvo, HPP, Del, Aple, Azus, etc.	Se corrigen a la marca real
Sucursales mal escritas	20 variantes de solo 6 sucursales	Se unifican a su nombre correcto
Contactos vacíos	1.563 correos y 295 teléfonos	Se completan con No especificado
Nulos de distinta naturaleza	Descuento, ciudad, productos 2 y 3	Se tratan según su significado

Este diagnóstico guió todo el trabajo. Cada problema se atendió con una transformación específica, en un orden pensado para no arrastrar errores de un paso a otro.

El Proceso de Limpieza, Paso a Paso

La limpieza se hizo en un orden deliberado. A continuación se explica cada paso, qué se hizo y por qué.

Importación de los datos

El primer paso fue importar el archivo de facturas a Power BI mediante la opción de obtener datos desde un archivo de texto o CSV. Al importar, se eligió la opción de transformar los datos en lugar de cargarlos directamente, para entrar a Power Query y hacer la limpieza antes de llevar nada al modelo. Cargar de una vez habría metido los datos sucios al análisis, que es justo lo que se quiere evitar.

Eliminación de facturas duplicadas

Se detectaron trescientas siete facturas totalmente repetidas. Se eliminaron quitando los duplicados por la columna VentaID, que es el identificador único de cada factura. El razonamiento es que si un mismo identificador de venta aparece más de una vez, se trata de una fila repetida, porque cada venta real es única. Este paso se hizo al inicio, para no arrastrar filas repetidas por el resto de la limpieza y no distorsionar los conteos. Tras el paso, el conjunto quedó en treinta mil facturas únicas.

Estandarización de los nombres de columnas

La mayoría de las columnas venían en un formato de palabras pegadas con mayúscula inicial, pero algunas usaban guion bajo o minúsculas, lo que rompía la uniformidad. Se renombraron las columnas que no seguían el criterio: Cliente_Nombre pasó a ClienteNombre, Direccion_Cliente pasó a DireccionCliente, y edadcliente pasó a EdadCliente. El criterio elegido

fue el de palabras pegadas con mayúscula inicial en cada palabra, el mismo del ejemplo de la consigna. Tener todos los nombres bajo una misma lógica evita confusiones y errores al referirse a las columnas en los análisis siguientes.

Asignación de los tipos de dato

Cada columna recibió el tipo de dato que le corresponde, porque de eso depende que los cálculos, los filtros y los ordenamientos funcionen. La fecha de venta se definió como tipo fecha, para poder ordenarla y extraer de ella el año y el mes. Los identificadores se definieron como texto, porque un identificador no se suma ni se promedia, solo identifica, y dejarlo como número podría llevar a operaciones sin sentido. Los precios, subtotales, totales y el descuento se definieron como número decimal, porque manejan valores con decimales. Las cantidades de producto se definieron como número entero, porque se cuentan en unidades completas. Asignar bien los tipos es un paso silencioso pero fundamental, porque un dato con el tipo equivocado se comporta mal en todo lo que venga después.

Normalización de las ciudades

La columna de ciudad de la sucursal tenía cada ciudad escrita de varias formas, con distintas combinaciones de mayúsculas y tildes. Por ejemplo, Medellín aparecía como medellin, Medellin, medellín y Medellín, es decir, la misma ciudad contada como cuatro valores distintos. Se unificó cada ciudad a una sola forma correcta, con la opción de reemplazar valores, convirtiendo todas las variantes en Medellín, Bogotá, Cali y Pereira según correspondiera. Esta normalización es crítica, porque si no se hace, al analizar las ventas por ciudad el programa trataría cada variante como una ciudad diferente, y los totales de una misma ciudad quedarían partidos en varios pedazos, dando un análisis equivocado.

Normalización de las marcas de producto

Las marcas de los productos tenían un problema similar, pero por errores de escritura. Cada marca aparecía con su nombre correcto y con una o más versiones mal escritas, como errores de dedo. Estos errores estaban en las tres columnas de marca, la del producto uno, la del dos y la del tres, así que se corrigieron en las tres. La tabla siguiente muestra las correcciones aplicadas.

Escrito mal	Correcto
Lenvo	Lenovo
HPP	HP
Del	Dell
Delll	Dell
Aple	Apple
Azus	Asus
Acr	Acer
Samsng	Samsung
Microsofft	Microsoft
MSY	MSI
Razor	Razer

Un caso particular fue el de Dell, que aparecía mal de dos formas, como Del y como Delll con tres letras. Al reemplazar Del hubo que usar la opción de coincidencia con la celda completa, para que solo cambiara las celdas que decían exactamente Del y no afectara otras palabras que contuvieran esas letras. Corregir las marcas garantiza que, al contar o agrupar las ventas por marca, cada una sume de forma completa y no aparezca dividida por un error de escritura.

Normalización de los nombres de sucursal

La columna del nombre de la sucursal presentaba el mismo tipo de desorden que las ciudades. Una misma sucursal aparecía escrita de múltiples formas, combinando variaciones de mayúsculas, tildes y espacios. Por ejemplo, la sucursal principal de Medellín aparecía como TechCore medellin #1, TechCore medellín #1 y TechCore Medellín #1, tres formas distintas para el mismo lugar. En total, el conteo inicial arrojaba veinte sucursales aparentes.

El análisis reveló que esas veinte variantes correspondían en realidad a solo seis sucursales: dos en Medellín, dos en Bogotá, una en Cali y una en Pereira. Se aplicaron catorce reemplazos para unificar cada variante en el nombre correcto de su sucursal, usando la coincidencia con la celda completa para no afectar los valores que ya estaban bien escritos. Este paso es tan importante como el de las ciudades, porque sin él el análisis por sucursal habría fragmentado las ventas de un mismo local en varios registros distintos, dando conclusiones equivocadas sobre el desempeño de cada tienda.

Tratamiento de los métodos de pago vacíos

La columna de método de pago tenía mil cuatrocientas cincuenta y nueve facturas sin valor. Estos vacíos se reemplazaron por el texto No especificado, tal como pide la consigna. La razón es que un campo vacío no comunica nada, mientras que No especificado deja constancia explícita de que ese dato no se registró en la factura. Así el vacío se convierte en una categoría más, que se puede contar y analizar, en lugar de un hueco en los datos.

Tratamiento de los demás valores nulos

Este fue el paso que más criterio requirió, porque no todos los valores nulos significan lo mismo ni se tratan igual. Tratar todos los nulos de la misma forma habría sido un error de análisis. Se distinguieron tres casos.

El descuento nulo. La columna de descuento tenía seis mil ochenta facturas sin valor. Estos nulos se reemplazaron por cero, porque en este caso el cero es el valor real: una factura sin descuento registrado es una factura con descuento de cero. Aquí el cero dice la verdad del dato.

La ciudad nula. La columna de ciudad tenía cuatrocientas treinta y un facturas sin valor. Estos nulos se reemplazaron por No especificado, con el mismo criterio del método de pago: dejar constancia explícita de que el dato no se registró, en lugar de un vacío.

El correo y el teléfono del cliente nulos. La columna de correo tenía mil quinientas sesenta y tres facturas sin valor, y la de teléfono doscientas noventa y cinco. Ambos son campos de contacto, y sus vacíos se reemplazaron por No especificado, siguiendo el mismo criterio aplicado al método de pago y a la ciudad: dejar constancia explícita de que el dato no se registró, en lugar de un campo en blanco que no comunica nada.

Los productos dos y tres nulos. Las columnas del segundo y tercer producto tenían muchos nulos, alrededor de diez mil y veinte mil respectivamente. Estos nulos no se rellenaron, y esa es una decisión deliberada. El motivo es que esos nulos no son un error ni un dato perdido: significan que la factura vendió uno o dos productos, no tres. Rellenarlos con cero habría inventado productos que nunca existieron, con cantidad y precio cero, lo que ensuciaría cualquier análisis posterior, como el conteo de productos vendidos o el promedio de cantidades. Por eso se dejaron como están. La consigna pide imputar con cero solo cuando sea pertinente, y en este caso no lo es.

Esta distinción es la parte más importante del criterio de limpieza. La regla que se siguió es simple: el cero se usa cuando cero es el valor verdadero del campo, y no se usa cuando el vacío

significa que algo no ocurrió. Entender esta diferencia es lo que separa una limpieza hecha con criterio de una hecha de forma mecánica.

Creación de columnas derivadas

Como último paso de transformación, se crearon dos columnas nuevas a partir de la fecha de venta: el año y el mes. Se generaron con la función de fecha de Power Query, que extrae esos valores de una columna de tipo fecha. Estas columnas, año de venta y mes de venta, quedaron como número entero, porque el año y el mes son valores sin decimales. Su utilidad es que permiten agrupar y comparar las ventas por período en los análisis siguientes, por ejemplo para ver la evolución de las ventas mes a mes o comparar años. Agregarlas ahora deja el terreno preparado para el Avance 3.

Un Hallazgo en la Exportación, las Fechas

Al exportar el conjunto limpio y revisar el archivo resultante, detecté un problema que no era visible desde Power BI. Las columnas de fecha y hora de venta no se habían exportado con sus valores reales. En su lugar, cada fila mostraba una etiqueta interna del programa, la misma repetida treinta mil veces. Las fechas se habían perdido en la exportación.

La causa es una limitación conocida al exportar columnas de tipo fecha desde Power BI hacia un archivo de texto: el valor no se convierte de forma automática y queda reemplazado por el nombre del tipo de dato. La solución fue convertir las columnas de fecha y hora al tipo texto justo antes de exportar, con lo que sus valores reales sí quedaron escritos en el archivo. Un detalle importante es que esa conversión debe ser el último paso de la secuencia, después de haber creado las columnas de año y mes, porque esas columnas se derivan de la fecha y necesitan que siga siendo de tipo fecha en el momento de generarlas.

Este hallazgo tiene valor más allá del problema puntual, porque muestra la importancia de verificar el resultado del trabajo y no darlo por bueno sin revisarlo. Si no hubiera abierto el archivo exportado para comprobarlo, el error habría pasado inadvertido y habría dejado el avance siguiente sin la información de fechas, que es esencial para cualquier análisis temporal.

Resultados de la Limpieza

Al terminar el proceso, el conjunto de datos quedó completamente limpio. De las treinta mil trescientas siete facturas iniciales, se eliminaron las trescientas siete duplicadas, quedando treinta mil facturas únicas. Las ciudades quedaron unificadas en cuatro valores correctos, sin ningún vacío. Las sucursales quedaron unificadas en sus seis nombres reales, de las veinte variantes que había. Las marcas quedaron unificadas en sus diez nombres correctos, sin ninguna versión mal escrita. Los métodos de pago, los correos y los teléfonos quedaron sin vacíos, con los faltantes marcados como No especificado. El descuento quedó sin nulos, con los faltantes en cero. Las fechas y horas de venta se conservaron con sus valores reales tras corregir el problema de exportación. Los nombres de columnas quedaron estandarizados, los tipos de dato asignados correctamente, y se agregaron las columnas de año y mes. El dataset limpio se exportó a un archivo para su uso en el Avance 2.

Hallazgos Principales

El trabajo de limpieza dejó varios hallazgos que vale la pena destacar. El más importante es que los datos crudos tenían una gran cantidad de inconsistencias de escritura en los campos de texto, tanto en las ciudades como en las sucursales y las marcas, con la misma entidad escrita de muchas formas distintas. Este es un problema típico de los datos capturados a mano, y si no se corrige, fragmenta cualquier análisis por categoría. Otro hallazgo relevante es la presencia de nulos

de distinta naturaleza en el mismo conjunto, unos que representan la ausencia real de un valor y otros que simplemente indican que un evento no ocurrió, lo que exigió tratarlos de forma diferenciada. Estos hallazgos confirman que una limpieza cuidadosa, hecha con criterio y no de forma automática, es un paso indispensable antes de cualquier análisis.

Resumen del Avance

El Avance 1 tomó la base cruda de facturas de TechCore y la dejó lista para el análisis. Se importó el archivo a Power Query, se eliminaron los duplicados, se estandarizaron los nombres de columnas y los tipos de dato, se normalizaron las ciudades, las sucursales y las marcas, se trataron los valores nulos según su naturaleza, se agregaron columnas derivadas de la fecha, y se corrigió un problema de exportación que afectaba a las fechas. Cada transformación quedó registrada en la secuencia de pasos de Power Query, que documenta el proceso completo. El resultado son treinta mil facturas limpias y confiables, entregadas en el archivo de Power BI con sus pasos y en el archivo de datos exportado, listas para el modelado del Avance 2.