

Proyecto Integrador Módulo 3

TechCore, Análisis de Ventas

Avance 2, Modelo Relacional

Simón Bedoya

Soy Henry, Carrera de Data Science

2026

Descripción del Avance

Tras completar la limpieza y estandarización de la base de facturación en el Avance 1, DataVision Analytics asigna la segunda fase del proyecto para TechCore. El objetivo de esta etapa es diseñar e implementar el modelo relacional que integra la información de ventas con las demás entidades del negocio, asegurando coherencia, integridad y trazabilidad de los datos.

El trabajo consiste en cargar en Python el dataset limpio del avance anterior, identificar las entidades principales y sus relaciones, definir las claves primarias y foráneas, y construir las tablas que conforman la estructura del modelo. Sobre esas tablas se realizan verificaciones de consistencia y control de calidad, se generan reportes exploratorios para confirmar la correcta estructuración, y se produce un archivo de Excel que servirá como base de datos definitiva para el dashboard de la siguiente fase.

Todo el proceso quedó registrado en un notebook de Python, que documenta paso a paso el análisis, las decisiones y las correcciones aplicadas.

Objetivo del Avance

El objetivo es transformar una tabla plana en un modelo relacional coherente. La tabla que viene del Avance 1 tiene treinta mil filas y treinta y dos columnas, y mezcla toda la información en un solo lugar. El modelo relacional separa esa información en tablas por entidad, conectadas mediante llaves, de forma que cada dato viva en un único lugar y las relaciones entre entidades queden explícitas y verificables.

Por qué un Modelo Relacional

Una tabla plana como la del Avance 1 tiene un problema estructural que se llama redundancia. Si un cliente compró diez veces, su nombre, correo, teléfono y dirección aparecen repetidos diez veces. Si un producto se vendió en mil facturas, su nombre, marca y precio están escritos mil veces. Esa repetición trae tres consecuencias negativas.

Desperdicio de espacio. La misma información se almacena una y otra vez sin necesidad, lo que hace el conjunto de datos más pesado de lo que debería ser.

Riesgo de inconsistencia. Si hay que corregir el correo de un cliente, habría que corregirlo en las diez filas donde aparece. Si se corrige en unas y en otras no, el mismo cliente queda con dos correos distintos, y el dato deja de ser confiable.

Dificultad para analizar. Sin una estructura clara de entidades, resulta complicado responder preguntas como cuántos clientes distintos tiene la empresa, porque el cliente no existe como una entidad separada, sino como columnas repetidas dentro de las ventas.

El modelo relacional resuelve estos tres problemas. Cada entidad tiene su propia tabla, cada dato se guarda una sola vez, y las tablas se conectan mediante llaves que hacen explícitas las relaciones del negocio.

Control de Calidad y Hallazgos

Antes de construir el modelo se validó la consistencia de los datos. Un modelo relacional levantado sobre datos incongruentes propaga esos errores a todo el análisis posterior, así que este paso es indispensable. El análisis detectó cuatro incongruencias que se explican a continuación, cada una con su corrección.

Hallazgo uno: precios con un cero de más

Al revisar el catálogo, cada uno de los cuarenta productos aparecía con dos precios distintos. Un producto debería tener un solo precio, así que había que entender el motivo de esa duplicidad.

Comparando los dos precios de cada producto surgió un patrón revelador: uno es exactamente diez veces el otro, en los cuarenta casos, sin una sola excepción. La razón entre el precio mayor y el menor es siempre diez. Un patrón tan sistemático no es casualidad ni corresponde a precios legítimos distintos, como podrían ser una promoción o un cambio de precio en el tiempo. Es un error de captura: a una parte de los registros se les agregó un cero de más.

Los valores confirman la interpretación. Un Apple MacBook Pro 16 aparecía a nueve millones seiscientos mil pesos y también a noventa y seis millones. Un Acer Aspire 5 de gama de entrada aparecía a dos millones y a veinte millones. Los precios reales de estos equipos corresponden a los valores bajos, mientras que los altos son diez veces lo que deberían ser.

La corrección. Se tomó el precio menor de cada producto como el correcto, y se aplicó a todos sus registros. De ese modo cada producto quedó con un precio único y correcto, que es lo que exige la tabla de Productos del modelo.

Hallazgo dos: el total de la factura no cuadraba

El total de una factura debería ser la suma de los subtotales de sus productos, menos el descuento aplicado. Al verificar esa relación, el resultado fue contundente: el total no cuadraba en ninguna de las treinta mil facturas.

La causa está relacionada con el hallazgo anterior. Como los precios traían el error del cero de más de forma mezclada, unos inflados y otros no, el total del archivo se calculó sobre valores erróneos y quedó sin correspondencia con sus componentes.

La corrección. Se recalcularon los subtotales de cada producto multiplicando el precio corregido por la cantidad, y luego el total de cada factura como la suma de sus subtotales menos el descuento. Con esto los números quedaron coherentes y verificables, y el modelo se construye sobre datos que cuadran.

Hallazgo tres: la ciudad se podía recuperar

En el Avance 1, las ciudades que venían vacías se rellenaron con el texto No especificado, siguiendo el criterio de dejar constancia explícita del dato faltante. Al construir el modelo, esa decisión mostró una consecuencia inesperada: cada sucursal aparecía dos veces, una con su ciudad correcta y otra con No especificado, lo que producía doce sucursales cuando en realidad solo existen seis.

El análisis del problema llevó a una conclusión importante: la ciudad nunca estuvo realmente perdida. El nombre de la sucursal contiene la ciudad. Si una sucursal se llama TechCore Bogotá número uno, su ciudad es Bogotá, sin ambigüedad posible. Rellenar con No especificado descartó una información que estaba disponible en otra columna.

La corrección. Se dedujo la ciudad de cada factura a partir del nombre de su sucursal. Con esto desapareció el valor No especificado de la columna de ciudad, cada sucursal quedó asociada a su ciudad real, y el conteo de sucursales se corrigió a las seis que existen.

Este hallazgo deja una lección de método. Una decisión razonable en un momento del proceso puede revisarse cuando aparece nueva información. Al construir el modelo se hizo evidente algo que en la fase de limpieza no lo era, y lo correcto fue corregirlo en lugar de mantener una decisión que ya no era la mejor.

Hallazgo cuatro: el descuento cambió de escala

El descuento presentaba un comportamiento inesperado en los cálculos. Al aplicar la fórmula del total, los resultados salían negativos, lo que no tiene sentido para unas ventas.

La causa era una diferencia de escala. En el archivo original el descuento venía expresado como una fracción decimal, con valores entre cero y cero coma quince, que representan porcentajes del cero al quince por ciento. Al asignar el tipo de dato en Power Query, la columna quedó como número entero, y en el archivo exportado el descuento aparece con valores enteros de cero, uno, cinco y quince, que ahora representan el porcentaje de forma directa. La fórmula que restaba el descuento como fracción, al recibir un quince en lugar de un cero coma quince, producía un multiplicador negativo.

La corrección. Se ajustó la fórmula para dividir el descuento entre cien antes de aplicarlo, convirtiéndolo de porcentaje a fracción. Con ese ajuste los totales quedaron correctos y todas las facturas cuadran.

Este hallazgo muestra que el tipo de dato no es solo una etiqueta técnica: puede alterar el significado del valor. Un cambio de tipo aparentemente inocuo transformó una fracción en un entero y cambió la escala del dato, con consecuencias en todos los cálculos que dependían de él.

Diseño del Modelo Relacional

Con los datos ya coherentes se procedió al diseño. El primer paso fue identificar las entidades del negocio, es decir, las cosas del mundo real sobre las que la empresa guarda información. Se identificaron siete, cada una con su propia tabla y su llave primaria.

Tabla	Qué representa	Llave primaria
Ciudades	Las ciudades donde opera TechCore	CiudadID

Tabla	Qué representa	Llave primaria
Sucursales	Las tiendas físicas de la cadena	SucursalID
Vendedores	El personal de ventas	VendedorID
Clientes	Las personas que compran	ClienteID
Productos	El catálogo de equipos	ProductoID
Facturas	Cada venta realizada	FacturaID
DetalleFacturas	Cada producto de cada venta	DetalleID

Las llaves del modelo

Una llave primaria es la columna que identifica de forma única cada fila de una tabla. Ningún valor de la llave primaria puede repetirse ni estar vacío, porque de lo contrario dejaría de identificar. Una llave foránea es una columna que apunta a la llave primaria de otra tabla, y es lo que crea la relación entre ambas. Cuando la tabla de Facturas guarda un ClienteID, ese número apunta a un cliente concreto de la tabla de Clientes, y esa referencia es la relación.

El modelo tiene seis llaves foráneas. La tabla de Sucursales lleva CiudadID, que la conecta con su ciudad. La tabla de Facturas lleva tres, SucursalID, ClienteID y VendedorID, que la conectan con la sucursal donde se hizo la venta, el cliente que compró y el vendedor que atendió. La tabla de DetalleFacturas lleva dos, FacturaID y ProductoID, que la conectan con la factura a la que pertenece la línea y con el producto que se vendió.

La transformación clave: de columnas a filas

La decisión de diseño más importante del avance tiene que ver con los productos. En el dataset del Avance 1, cada factura puede contener hasta tres productos, que están guardados en

columnas repetidas dentro de la misma fila: hay un grupo de columnas para el primer producto, otro para el segundo y otro para el tercero.

Esa estructura tiene dos problemas serios. El primero es que impone un límite artificial: si mañana una factura tuviera cuatro productos, no cabría, habría que agregar cinco columnas nuevas a la tabla. El segundo es que desperdicia espacio, porque las facturas de un solo producto dejan diez columnas vacías.

El modelo relacional resuelve esto con la tabla de DetalleFacturas. En lugar de tres grupos de columnas, cada producto de cada factura se convierte en una fila del detalle. Una factura con tres productos genera tres filas, una con dos productos genera dos, y una con un solo producto genera una. La tabla de detalle no tiene límite de productos por factura, y no desperdicia espacio.

El resultado de esta transformación es que las treinta mil facturas produjeron sesenta mil cincuenta y nueve líneas de detalle, con un promedio de dos productos por factura.

La identificación de los clientes

La construcción de la tabla de Clientes exigió una decisión de diseño que vale la pena explicar, porque no era evidente. El dataset no trae un identificador de cliente, así que había que construirlo, y para eso hacía falta definir cuándo dos filas hablan de la misma persona.

La opción natural habría sido usar el correo electrónico, porque un correo suele ser único por persona. Al verificarlo en los datos, la hipótesis no se sostuvo: seiscientos setenta y nueve correos aparecen asociados a personas distintas. Por ejemplo, un mismo correo figura con dos nombres diferentes. Esto ocurre porque los correos se generaron a partir del nombre de pila más un número, de modo que dos personas con el mismo primer nombre pueden terminar compartiendo correo. Usar el correo como identificador habría fusionado personas distintas en un solo cliente, un error grave en el modelo.

La decisión. Se identificó a cada cliente por la combinación completa de sus datos: nombre, género, edad, correo, teléfono y dirección. Si dos filas coinciden en todos esos campos, corresponden a la misma persona. Este criterio es más robusto que confiar en un solo campo, y produjo diecisiete mil cuatrocientos cincuenta y tres clientes únicos.

Las Tablas del Modelo

Las siete tablas quedaron con las siguientes dimensiones.

Tabla	Filas	Contenido
Ciudades	4	Bogotá, Cali, Medellín, Pereira
Sucursales	6	Dos en Medellín, dos en Bogotá, una en Cali, una en Pereira
Vendedores	30	El personal de ventas de la cadena
Clientes	17.453	Los compradores únicos identificados
Productos	40	El catálogo completo de equipos
Facturas	30.000	Todas las ventas del período
DetalleFacturas	60.059	Cada producto de cada venta

Las Relaciones y su Cardinalidad

La cardinalidad describe cuántos registros de una tabla se relacionan con cuántos de otra. En este modelo todas las relaciones son de uno a muchos, que es la forma más común y la que corresponde a la lógica del negocio. El diagrama entidad relación que acompaña a este documento las representa de forma gráfica.

Relación	Cardinalidad	Qué significa
Ciudades a Sucursales	1 a N	Una ciudad tiene varias sucursales, cada sucursal está en una ciudad
Sucursales a Facturas	1 a N	Una sucursal registra muchas ventas, cada venta se hizo en una sucursal
Clientes a Facturas	1 a N	Un cliente realiza muchas compras, cada factura es de un cliente
Vendedores a Facturas	1 a N	Un vendedor atiende muchas ventas, cada factura la atendió un vendedor
Facturas a DetalleFacturas	1 a N	Una factura contiene varias líneas, cada línea pertenece a una factura
Productos a DetalleFacturas	1 a N	Un producto aparece en muchas líneas, cada línea es de un producto

Un matiz de precisión en el modelado merece mención. La relación entre Facturas y DetalleFacturas es de uno a uno o muchos, no de cero a muchos, porque toda factura tiene al menos un producto: no existe una venta sin nada vendido. Las demás relaciones admiten el cero, porque una ciudad podría existir sin sucursales, o un producto podría estar en el catálogo sin haberse vendido nunca.

Validación de la Integridad Referencial

La integridad referencial significa que toda llave foránea apunta a un registro que existe de verdad. Si una línea de detalle apunta a una factura que no existe, o a un producto que no está en el catálogo, el modelo está roto. Esos registros que apuntan a la nada se llaman huérfanos, y el objetivo es que no haya ninguno.

Se verificaron las seis relaciones del modelo. Cada validación cuenta los registros cuya llave foránea no encuentra correspondencia en la tabla de destino, de modo que el resultado esperado de cada una es cero.

Validación	Huérfanos	Estado
DetalleFacturas apunta a Facturas	0	Correcto
DetalleFacturas apunta a Productos	0	Correcto
Facturas apunta a Sucursales	0	Correcto
Facturas apunta a Clientes	0	Correcto
Facturas apunta a Vendedores	0	Correcto
Sucursales apunta a Ciudades	0	Correcto

Las seis validaciones pasaron sin un solo registro huérfano. También se verificó que las llaves primarias de las siete tablas sean únicas y no tengan valores vacíos, condición indispensable para que cumplan su función de identificar cada fila. Las siete pasaron la verificación.

Validación de coherencia de los totales

Una tercera validación comprueba que la transformación de columnas a filas no haya perdido ni duplicado información. Para cada factura se suman los subtotales de sus líneas de detalle, se aplica el descuento, y el resultado debe coincidir con el total de la factura. Las treinta mil facturas cuadran con su detalle, lo que confirma que la transformación fue correcta y que ninguna venta se perdió ni se contó dos veces.

Reportes Exploratorios

La consigna pide generar reportes rápidos para confirmar que el modelo quedó bien estructurado. Estos reportes cruzan varias tablas del modelo, de modo que si producen resultados coherentes, quedan validadas las relaciones que hacen posible ese cruce.

Total de ventas por marca

Este reporte cruza la tabla de detalle con la de productos, para conocer la marca de cada línea vendida, y suma las ventas de cada una. Los valores están en millones de pesos.

Marca	Ventas (millones)	Unidades
Lenovo	656.166	120.913
HP	529.810	108.968
Dell	476.147	89.008
Apple	422.534	58.456
Asus	182.941	44.871
Acer	121.789	39.497
Samsung	67.596	14.093
MSI	47.754	7.584
Microsoft	45.194	9.475
Razer	22.275	2.732

Lenovo lidera las ventas tanto en valor como en unidades, seguida por HP y Dell. Un dato que llama la atención es el caso de Apple: ocupa el cuarto lugar en valor de ventas pero el cuarto también en unidades, con bastante menos volumen que las tres primeras, lo que se explica por su precio unitario más alto. Vende menos equipos pero cada uno aporta más ingreso.

Top diez de productos más vendidos

Este reporte identifica los productos con más unidades vendidas, cruzando el detalle con el catálogo.

Producto	Marca	Unidades
HP Spectre x360	HP	41.350
Lenovo ThinkPad X1 Carbon	Lenovo	32.724
Lenovo Legion 5 Pro	Lenovo	32.033
Lenovo Yoga 7i	Lenovo	28.605
HP Omen 16	HP	27.781
Lenovo IdeaPad 5	Lenovo	27.551
Dell Latitude 7420	Dell	24.910
Dell XPS 13	Dell	24.812
HP Pavilion 15	HP	22.488
Dell Alienware m15	Dell	19.939

El HP Spectre x360 es el producto más vendido de la cadena, con una diferencia clara sobre el segundo. Lenovo coloca cuatro modelos en el top diez, lo que explica su liderazgo general en ventas. Las tres marcas que dominan el listado, HP, Lenovo y Dell, son las mismas que lideran las ventas totales, lo que da consistencia al análisis.

Se generaron también reportes de ventas por ciudad y por año, que cruzan hasta cuatro tablas del modelo. Que esos cruces funcionen y produzcan resultados coherentes confirma que las relaciones están correctamente definidas.

El Archivo de Salida

Las siete tablas se exportaron a un archivo de Excel llamado modeloVentas, con cada tabla en su propia hoja. Este formato permite que Power BI lea cada hoja como una tabla independiente y reconstruya allí las relaciones del modelo. El archivo constituye la base de datos definitiva sobre la que se desarrollará el dashboard de la siguiente fase.

Resumen del Avance

El Avance 2 transformó una tabla plana en un modelo relacional coherente y validado. El control de calidad detectó y corrigió cuatro incongruencias en los datos: precios inflados por un cero de más, totales que no cuadraban con sus componentes, ciudades marcadas como no especificadas que en realidad podían recuperarse del nombre de la sucursal, y un descuento cuya escala había cambiado al modificar su tipo de dato.

Sobre esos datos corregidos se construyeron siete tablas conectadas por seis relaciones, todas de uno a muchos, con sus llaves primarias y foráneas definidas. La transformación central consistió en llevar los productos de columnas repetidas a filas de una tabla de detalle, lo que elimina el límite artificial de tres productos por factura y hace el modelo extensible.

Las validaciones confirmaron que el modelo es sólido: no hay registros huérfanos en ninguna de las seis relaciones, las llaves primarias son únicas en las siete tablas, y los totales de las treinta mil facturas cuadran con la suma de sus detalles. Los reportes exploratorios producen resultados coherentes que confirman la correcta estructuración. El modelo queda listo para alimentar las visualizaciones del Avance 3.